

GO UNITE! Strategien zur Sammlung und Sichtbarkeit von Forschungsdaten der eigenen Institution

Dorothea Strecker	Birte Cordes	Anna Daudrich
Jessica Hiller	Isabel Schuster	Martin Spenger

2026-10-01

Inhaltsverzeichnis

Über dieses Dokument	4
Beitragende	4
 I. Strategien	 5
1. Einführung	6
1.1. Motivation zur Durchführung des Datenmonitorings an der eigenen Einrichtung	6
1.2. Struktur des Dokuments	7
2. Vorüberlegungen	8
2.1. Ziele	8
2.2. Herausforderungen	9
2.2.1. Technische Herausforderungen	9
2.2.2. Institutionelle Herausforderungen	10
3. Durchführung	12
3.1. Grundprinzipien und schematischer Ablauf	12
3.2. Suchstrategien	13
3.2.1. Direkte Suche	14
3.2.2. Indirekte Suche	14
3.3. Datenquellen für die direkte Suche	16
3.3.1. BASE	17
3.3.2. DataCite	17
3.3.3. OpenAIRE	18
3.3.4. OpenAlex	18
4. Verwendung	20
4.1. Zielsysteme	20
4.1.1. Forschungsinformationssysteme	20
4.1.2. Institutionelles Repositorium	22
4.1.3. Hochschulbibliografie und Bibliothekskatalog	22
4.2. Schritte zum Ingest in das Zielsystem	23

5. Vorbereitung	25
5.1. Organisatorische Maßnahmen für Sammlungen	25
5.1.1. Leit- und Richtlinien	25
5.1.2. Institutsseitige Empfehlungen für die Repositorienwahl	26
5.1.3. Technische Voraussetzungen schaffen	26
5.1.4. Teilnahme am ORCID-DE Konsortium	26
5.2. Motivation und Befähigung von Forschenden	27
5.2.1. Anreizsysteme	27
5.2.2. Informationsangebote für Forschende	27
6. Zusammenfassung	29
Literaturverzeichnis	30
II. Notebooks	33

Über dieses Dokument

Dieses Dokument zeigt praxisnah, wie verstreut veröffentlichte Forschungsdaten effizient identifiziert und der eigenen Einrichtung zugeordnet werden können.

Der Teil **Strategien** enthält allgemeine Überlegungen zur Konzeption und Durchführung des Monitorings von institutionellem Forschungsdatenoutput.

Aktuell arbeiten wir ergänzend an **Notebooks**, die Code und Text kombinieren und beispielhaft zeigen, wie bestimmte Datenquellen abgefragt werden können. Die Notebooks werden voraussichtlich in Q1 2027 veröffentlicht.

Diese Version ist eine Aktualisierung und Überarbeitung von:

Putnings, M., Daudrich, A., Dille, N., Iarkaeva, A., Kühner, J., & Wollmann, A. (2024). GO UNITE! Empfehlungen zur Sammlung und Sichtbarkeit von Forschungsdaten der eigenen Institution. Zenodo. <https://doi.org/10.5281/zenodo.11102368>

Beitragende

Anastasiia Iarkaeva ; [0000-0002-7370-1663](https://orcid.org/0000-0002-7370-1663) ; Berlin Institute of Health, Charité - Universitätsmedizin Berlin, Deutschland

Markus Putnings ; [0000-0002-6014-9048](https://orcid.org/0000-0002-6014-9048) ; Bibliothek, Technische Hochschule Deggendorf, Deutschland

Esther Asef ; [0000-0003-2411-4953](https://orcid.org/0000-0003-2411-4953) ; Universitätsbibliothek, Charité - Universitätsmedizin Berlin, Deutschland

Christian Malzer ; [0009-0005-0522-7102](https://orcid.org/0009-0005-0522-7102) ; Bibliothek, Universität Würzburg, Deutschland

Teil I.

Strategien

1. Einführung

Dieses Dokument verfolgt das Ziel, praxisorientierte Strategien für die Identifizierung, zentrale Erfassung und das Monitoring von Forschungsdaten bereitzustellen, die von Angehörigen einer Institution dezentral auf verschiedenen Plattformen – beispielsweise Zenodo, Dryad oder fachspezifischen Repositorien - publiziert wurden. Es baut auf dem Dokument „GO UNITE! Empfehlungen zur Sammlung und Sichtbarkeit von Forschungsdaten der eigenen Institution“ (Putnings u. a. (2024)) auf, wurde aber stark überarbeitet - einerseits aufgrund inhaltlicher Weiterentwicklungen, andererseits um die Praxisrelevanz zu erhöhen.

In erster Linie richtet sich das Dokument an Personen, die mit dem Monitoring und der Erfassung von Forschungsdaten betraut sind, etwa Forschungsdatenbeauftragte, Mitarbeitende von Forschungsinformationssystemen (FIS) sowie Bibliothekar:innen, aber auch an alle, die sich sonst für dieses Thema interessieren.

In diesem Dokument umfasst der Begriff „Forschungsdaten“ sowohl Daten im engeren Sinne – etwa Mess- und Beobachtungsdaten, Laborergebnisse, audiovisuelle Materialien, Texte, Umfragedaten, Sammlungsobjekte oder Proben – als auch den zugehörigen Code bzw. die Software, sofern diese ebenfalls in Datenrepositorien veröffentlicht wurden. Der primäre Fokus liegt auf Datensätzen, doch die hier beschriebenen Suchstrategien differenzieren nicht zwischen Daten- und Codepublikationen. Für eine gezielte und umfassende Erhebung veröffentlichter Forschungssoftware müssten zusätzlich zu den hier genannten weitere, auf Software spezialisierte Publikationsplattformen und Datenquellen berücksichtigt werden.

Wie die Abfragen zum Zwecke des Monitorings dort funktionieren, ist nicht Gegenstand dieses Dokuments.

1.1. Motivation zur Durchführung des Datenmonitorings an der eigenen Einrichtung

Ein Monitoring und begleitende Maßnahmen, wie z. B. eine Indexierung von Forschungsdaten der eigenen Einrichtung, können maßgeblich dazu beitragen, deren Auffindbarkeit und Nutzbarkeit im institutionellen Kontext zu verbessern. Darüber hinaus erhöht sich dadurch die Sichtbarkeit der publizierten Forschungsergebnisse über institutionelle Grenzen hinaus, indem ihre Erschließung in externen Suchmaschinen, Harvesting-Diensten, Forschungsinformationssystemen und weiteren Aggregatoren erleichtert wird.

Die Sichtbarkeit von Forschungsdaten ist nicht nur im Hinblick auf deren Nachnutzung von Bedeutung, sondern gewinnt auch vor dem Hintergrund der zunehmenden Anerkennung von Forschungsdatenpublikationen als eigenständige wissenschaftliche Leistung an Relevanz. Entsprechend finden Forschungsdaten verstärkt Berücksichtigung in Verfahren der Bewertung wissenschaftlicher Leistungen.

1.2. Struktur des Dokuments

Die Struktur des Dokuments orientiert sich am Prozess der Identifizierung von Forschungsdaten. Entsprechend werden zunächst notwendige Vorarbeiten und Voraussetzungen dargestellt, danach die Durchführung beschrieben und schließlich weiterführende Perspektiven sowie Entwicklungsmöglichkeiten aufgezeigt.

Ergänzend zu diesen Handlungsempfehlungen wird voraussichtlich in Q1 2027 ein separates Dokument veröffentlicht, das als Ergänzung zu diesem Text zu verstehen ist. Darin wird anhand konkreter Praxisbeispiele beschrieben, wie einzelne Plattformen nach den Forschungsdaten der eigenen Institution durchsucht werden können.

Hilfreich sind darüber hinaus auch die Texte und Handreichungen, die von weiteren Unterarbeitsgruppen der AG Sammlung und Sichtbarkeit von Forschungsdaten der eigenen Institution entwickelt wurden.¹

¹<https://go-unite.de/index.php/aktivitaeten-und-publikationen/> (abgerufen am 30.09.2026)

2. Vorüberlegungen

In diesem Kapitel werden Vorüberlegungen, die wissenschaftlichen Einrichtungen bei der Konzeption von institutionellem Forschungsdatenmonitoring helfen können, thematisiert. Grundsätzlich ist es empfehlenswert, dass Einrichtungen, die ihren Forschungsdatenoutput erfassen möchten, zunächst ihre Ziele festlegen und die vorhandenen Ressourcen (insbesondere personelle Kapazitäten) bestimmen. Für die Implementierung von Monitoring-Initiativen bei limitierten Ressourcen werden Handlungsempfehlungen in einer Infobox vorgestellt.

2.1. Ziele

Je nach institutionellen Rahmenbedingungen und strategischen Anforderungen können Ziele und Anlässe eines Datenmonitorings variieren. Das Monitoring kann ganz allgemein der Erfassung publizierter Forschungsdaten dienen, etwa im Sinne einer Hochschulbibliografie, oder darüber hinaus als Grundlage für strategische Entscheidungen und die Weiterentwicklung des Forschungsdatenmanagements (FDM) genutzt werden. Zu den möglichen Anlässen und Zielen eines Datenmonitorings zählen unter anderem:

- Erweiterung von Dokumentationstypen in einem bereits bestehenden FIS
- die Überprüfung der Umsetzung von Leitlinien
- die Weiterentwicklung von Leitlinien
- die Unterstützung des Berichtswesens und der strategischen Organisationsentwicklung
- die Identifikation von Handlungsbedarfen im institutionellen FDM
- die Erfolgskontrolle bereits umgesetzter FDM-Maßnahmen
- die Berücksichtigung von Datenpublikationen in Einstellungs- und Evaluationsverfahren oder in der leistungsorientierten Mittelvergabe

Je nach Zielsetzung kann ein einmaliges oder ein permanentes Monitoring erforderlich sein:

- Ein **einmaliges Monitoring** dient der anlassbezogenen Erfassung und Auswertung publizierter Forschungsdaten, beispielsweise zur Vorbereitung einer Evaluation, zur Entwicklung einer institutionellen FDM-Policy oder zur Analyse des aktuellen Stands des Forschungsdatenmanagements.
- Im Gegensatz dazu verfolgt ein **permanentes Monitoring** das Ziel, publizierte Forschungsdaten kontinuierlich zu erfassen und auszuwerten, um Entwicklungen und Trends

über einen längeren Zeitraum zu beobachten. Dadurch können beispielsweise die Wirksamkeit von FDM-Maßnahmen regelmäßig überprüft und neue Handlungsbedarfe frühzeitig erkannt werden. Um das Ziel einer möglichst vollständigen regelmäßigen Erfassung der FD-Publikationen zu unterstützen, können verschiedene Maßnahmen etabliert werden. Dazu zählen beispielsweise Empfehlungen oder Vorgaben zur Nutzung bestimmter Repositorien, die Erfassung von Metadaten in einem zentralen institutionellen Verzeichnis (z. B. FIS) sowie die Berücksichtigung der Forschungsdatenpublikation im Rahmen leistungsorientierter Mittelvergabe.

2.2. Herausforderungen

Die Erfassung von Forschungsdatenpublikationen einer Einrichtung ist mit technischen und institutionellen Herausforderungen verbunden. Nachfolgend werden die wichtigsten Hürden dargestellt, um sie in der Konzeption zu berücksichtigen und realistisch planen zu können.

2.2.1. Technische Herausforderungen

Zunächst werden nun einige technische Herausforderungen vorgestellt, welche die Erfassung des Forschungsdatenoutputs beeinträchtigen. Wie diese Herausforderungen in der Praxis adressiert werden können, wird in [Kapitel 3](#) gezeigt.

1. Verschiedene Datenquellen und Suchstrategien

- **Auswahl geeigneter Datenquellen:** Welche Objekte deckt die Datenquelle ab? Enthält die Datenquelle die Metadaten, die für den Zweck erforderlich sind? Bietet die Datenquelle geeignete Zugänge und Ausgabeformate an? In [Kapitel 3.2](#) werden einige zentrale Datenquellen vorgestellt. Grundsätzlich sollten Datenquellen vor der Auswahl gründlich geprüft werden. Dazu zählt neben der Konsultation der Dokumentation auch ein Testdurchlauf, um Zugangswege und Ausgabeformate zu prüfen.
- **Auswahl geeigneter Suchstrategien:** Gibt es bereits Anhaltspunkte darüber, wo und wie Forschende der Einrichtung ihre Daten publizieren (beispielsweise aus Bedarfserhebungen)? Welche Suchstrategien können mit den gewählten Datenquellen und vorhandenen Ressourcen umgesetzt werden? In [Kapitel 3.1](#) werden verschiedene Suchstrategien vorgestellt. Empfehlenswert ist nach Möglichkeit die Kombination verschiedener Suchstrategien.

2. Eingeschränkte technische Kapazitäten

- **Auswahl geeigneter Werkzeuge:** Sind programmatische Abfragen möglich? Welche Werkzeuge stehen für die Weiterverarbeitung der Daten zur Verfügung (z. B. bestimmte Skriptsprachen oder Text- und Tabellenbearbeitungsprogramme)?

- **Bestimmen des Ressourceneinsatzes:** Welche personellen Kapazitäten stehen zur Verfügung – wie viele Personen können sich mit dem Thema beschäftigen und wie viel Arbeitszeit können sie darauf verwenden?
3. Vorgaben des Zielsystems
- **Inputformate und Metadatenfelder:** Welche Anforderungen stellt das Zielsystem?
 - **Importmöglichkeiten:** Verfügt das Zielsystem über Schnittstellen und wenn ja, welche? Welcher Maß an Automatisierung kann erreicht werden und welcher manueller Aufwand ist weiterhin notwendig?

2.2.2. Institutionelle Herausforderungen

Arbeitsgruppe 1 (Scoping the Needs of Open Science Monitoring) der Open Science Monitoring Initiative hat festgestellt, dass institutionelle Barrieren die größten Herausforderungen bei der Umsetzung von Monitoringaktivitäten darstellen (Salisu und Cortés, 2026). Dazu zählen begrenzte Ressourcen sowie mangelnde Governance und Nachhaltigkeit. Darum ist es wichtig, ausreichend personelle Kapazitäten für das Vorhaben einzuplanen und einen realistischen Zeitrahmen zu setzen. Zum Einstieg können die folgenden Ansätze in Betracht gezogen werden:

1. Wenn die verfügbaren Ressourcen beschränkt oder unklar sind, kann zunächst stufenweise vorgegangen werden. Dabei wird zuerst eine Minimalumsetzung anvisiert, beispielsweise in Form der Suchstrategie „direkte Suche“ (s. [Kapitel 3.2.1](#)) mit lediglich einer Datenquelle. Dieser Ansatz kann ggf. später erweitert werden, etwa indem mehr Datenquellen einbezogen werden, die Suchstrategie modifiziert oder die Erfassung zusätzlich auf Forschungssoftware ausgeweitet wird.
2. Empfehlenswert ist zunächst eine einmalige Durchführung mit detaillierter Dokumentation der Arbeitsschritte. Die so entstehende Basis unterstützt eine spätere Verstetigung und zeigt, ob institutionelles Forschungsdatenmonitoring grundsätzlich umsetzbar ist, bevor ein kontinuierlicher Betrieb etabliert wird. Strategische Fragen wie die Ansiedlung der Zuständigkeit oder eine weitgehende Automatisierung können vorerst zurückgestellt und erst bei einer Verstetigung angegangen werden.

 **Infobox:** Welche Optionen existieren bei beschränkten oder unklaren Ressourcen?

„Perfect is the enemy of good.” - Natürlich ist eine vollständige Erfassung wünschenswert. Aus den oben beschriebenen Gründen ist sie jedoch nicht immer realistisch. Wenn die „perfekte“ Lösung nicht möglich ist, können die folgenden Strategien ggf. dabei helfen, einen ersten Einstieg in das Monitoring von Forschungsdatenpublikationen zu erreichen:

- **Ressourcen mobilisieren:** Gibt es Personen oder Abteilungen an der Einrichtung, die ebenfalls Interesse an der Erfassung von Forschungsdatenpublikationen haben (Data Stewards, Fachreferent:innen, Entwicklungsplanung o. ä.) und die ggf.

Ressourcen beisteuern können?

- **Auf eine oder wenige Datenquellen beschränken:** Steckbriefartige Übersichten über ausgewählte Datenquellen sind am Ende von [Kapitel 3](#) zu finden. Relevant für die Entscheidung können u. a. die folgenden Aspekte sein:
 - **Scope**¹: Woher bezieht die Datenquelle ihre Daten? Welche weiteren Datenquellen sind inkludiert? Gibt es fachspezifische Quellen oder bestimmte Projekte, die auf jeden Fall enthalten sein sollen? Wenn möglichst viele Datenpublikationen gefunden werden sollen, empfiehlt sich ein Aggregator wie DataCite.
 - * **Abfragemöglichkeiten:** Passen sie zu den vorhandenen technischen Möglichkeiten? Kann z. B. die geplante Suchanfrage über die Nutzeroberfläche gestellt werden, falls keine Nutzung der API möglich ist? Ist ein Komplettexport der Trefferliste in einem geeigneten Dateiformat möglich?
 - * **Metadaten:** Sind bestimmte Metadaten besonders wichtig (z. B. Affiliations-Metadatenfeld)? Können diese bei der gewählten Datenquelle abgefragt werden?
 - * **Offenheit:** Ist die Datenquelle frei von Zugangs- und Nutzungsbeschränkungen?
- **Suche einschränken:** Lässt sich die Suche einschränken, beispielsweise auf Forschungsdatenpublikationen mit DOI oder auf bestimmte Metadatenfelder?
- **Suche präzisieren:** Wenige, konkrete Zielfragen formulieren und die Datensammlung und -auswertung darauf ausrichten
- **Vorhandene Verzeichnisse berücksichtigen:** Können bestehende Verzeichnisse (z. B. FIS, Hochschulbibliografie, Repositorien) bei dem Vorhaben helfen?
- **Vorgehen dokumentieren:** Durch eine detaillierte Dokumentation des Vorgehens kann auch angesichts schlecht planbarer Zeiträume sowie personeller und finanzieller Engpässe später immer wieder auf dem bisherigen Fortschritt aufgebaut werden

¹Mit „Scope“ ist hier „Geltungsbereich“ gemeint. Da der englische Begriff im Deutschen geläufig ist, verwenden wir ihn im gesamten Dokument.

3. Durchführung

Das folgende Kapitel behandelt die praktische Durchführung des Monitorings des institutionellen Forschungsdatenoutputs. Es stellt leitende Grundprinzipien vor und fasst den schematischen Ablauf von Monitoringaktivitäten zusammen. Zudem werden zwei Suchstrategien - die direkte und die indirekte Suche - beschrieben. Abschließend werden exemplarische Datenquellen für die direkte Suche präsentiert.

3.1. Grundprinzipien und schematischer Ablauf

Monitoringaktivitäten sollten grundsätzlich individuell auf die jeweilige Einrichtung zugeschnitten werden, einem klar definierten Anlass folgen, bestehende Rahmenbedingungen - etwa Leitlinien und Fächerprofile - berücksichtigen und alle relevanten Akteure einbeziehen, wobei diese je nach Einrichtung variieren.

Einige Grundprinzipien sind auf alle Monitoringaktivitäten im Kontext Open Science anwendbar. 2025 veröffentlichte eine Gruppe internationaler Expert:innen die “Principles of Open Science Monitoring” (Bobrov u. a. (2025)). Dieses Dokument formuliert Anforderungen an Monitoringaktivitäten wie die Offenheit und Qualität der genutzten Datenquellen oder die Berücksichtigung spezifischer Fächerkulturen. Einrichtungen, die ihren Forschungsdatenoutput messen möchten, wird nahegelegt, ihre Aktivitäten in regelmäßigen Abständen mit den Principles of Open Science Monitoring abzugleichen.

Die praktische Ausgestaltung des Monitorings hängt neben den Zielen von weiteren Faktoren ab, etwa den vorhandenen Ressourcen. In den meisten Fällen wird der Ablauf die folgenden Schritte beinhalten:

1. **Die Auswahl geeigneter Suchstrategien.** Diese werden in [Kapitel 3.2](#) näher vorgestellt.
2. **Die Auswahl geeigneter Datenquellen.** Einige Datenquellen werden exemplarisch in [Kapitel 3.3](#) präsentiert.
3. **Die Durchführung der Abfragen.** Um die Überprüfbarkeit der Ergebnisse und die Reproduzierbarkeit des Verfahrens sicherzustellen, sollte die Durchführung gründlich dokumentiert werden, etwa indem Skripte für die Abfragen erstellt und abgespeichert werden. Insbesondere die verwendeten Suchbegriffe, Filter und das Abfragedatum sind zu dokumentieren, etwa für die Einschränkung auf bestimmte Publikationstypen oder

Namensvarianten der Einrichtung. Einige Beispiele werden ergänzend zu diesem Dokument voraussichtlich ab Q1 2027 in Notebooks zur Verfügung gestellt.

4. **Die Bereinigung der Ergebnisse.** Nach der Durchführung der Abfragen muss die Treffermenge bereinigt werden. In erster Linie geht es hierbei um das Entfernen von Dubletten, die Zusammenfassung von Versionen und gegebenenfalls die einheitliche Ansetzung von Werten in Freitextfeldern. Die Vereinheitlichung von Werten in Freitextfeldern, etwa für die Namen von Autor:innen, Repositorien und Förderorganisationen, kann sehr aufwendig sein (Kirsch und Wink (2026)). Wenn Forschungsdaten über die Suche in Volltexten ermittelt werden, zählt dazu auch der Ausschluss von Fällen, die lediglich “Datennachnutzung” darstellen.
5. **Die Bewertung der Ergebnisse.** Die Treffermenge sollte auf Korrektheit überprüft werden, um falschpositive Treffer auszuschließen. Dazu zählt insbesondere eine Prüfung der Affiliationsangaben, um sicherzustellen, dass die gefundenen Forschungsdaten tatsächlich der Einrichtung zugeordnet werden können.

Nach diesen Prozessschritten können die Ergebnisse schließlich für die Weiterverarbeitung im Zielsystem aufbereitet werden (s. [Kapitel 4](#)).

Welche weiteren Maßnahmen zur Erleichterung zukünftiger Monitoringaktivitäten ergriffen werden können, wird in [Kapitel 5](#) genauer dargelegt.

3.2. Suchstrategien

Die grundlegende Herausforderung beim Monitoring des Forschungsdatenoutputs einer Einrichtung ist die gesicherte Herstellung eines Bezugs zwischen Forschungsdatensätzen und der Einrichtung. Diese Zuordnung kann durch zwei verschiedene Ansätze realisiert werden. Durch eine Kombination der beiden Ansätze erhöht sich die Treffermenge.

Der Bezug zwischen einer Einrichtung und einem Datensatz lässt sich **direkt** herstellen, indem Metadatenätze, die Forschungsdaten beschreiben, durchsucht werden – etwa nach Angaben zu Personen, welche die Datensätze erstellt haben, und ihrer Affiliation. Gee (2026) beschreibt die Durchführung dieser Suchstrategie umfassend am Beispiel der University of Texas. Häufig fehlen diese Angaben jedoch in den Metadaten, beispielsweise weil sie bei der Übergabe an ein Repository nicht mit überliefert werden (Robinson-Garcia u. a. (2017)).

Darum ist ergänzend die **indirekte** Suche über andere Forschungsoutputs, die der Einrichtung zugeordnet werden können, sinnvoll. Dazu zählen beispielsweise Zeitschriftenartikel, die auf zugrundeliegende Datensätze verweisen. Der Bezug zwischen einer Einrichtung und einem Datensatz wird dann indirekt über diesen Forschungsoutput hergestellt. Cohen u. a. (2026) verdeutlichen am Beispiel der Charité Universitätsmedizin Berlin, wie mit diesem Ansatz Forschungsdatenpublikationen identifiziert werden können.

Im Folgenden werden die beiden Ansätze näher beschrieben.

3.2.1. Direkte Suche

Forschungsdatensätze können einer Einrichtung direkt zugeordnet werden, wenn die Metadaten, die den Datensatz beschreiben, entsprechende Angaben enthalten. Für diese Suchstrategie können die unten beschriebenen Datenquellen genutzt werden.

Grundsätzlich sind hier zwei Ansätze denkbar: die Suche in Affiliationsangaben oder die Suche nach Autor:innen. Einige Datenquellen nutzen in ihren Metadaten persistente Identifikatoren für Institutionen (z. B. ROR IDs) und Autor:innen (z. B. ORCID IDs). Diese ermöglichen eine eindeutige Zuordnung zur Einrichtung bzw. Person, darum wäre diese Option besonders wünschenswert für das Monitoring. Da persistente Identifikatoren allerdings nicht immer mit angegeben werden, ist ergänzend eine Suche in Freitextfeldern zu empfehlen, etwa im Freitextfeld für den Namen der Institution. Bei der Suche in Affiliationsangaben sollten möglichst viele verschiedene Ansetzungsformen und Schreibweisen des Einrichtungsnamens genutzt werden, zum Beispiel neben “Humboldt-Universität zu Berlin” auch “HU Berlin” oder “Humboldt University Berlin”. Namensvarianten finden sich beispielsweise im ROR-Eintrag einer Einrichtung oder auch in der institutionellen Affiliationsrichtlinie, falls vorhanden.¹

Jede Suche wird verschiedene Treffermengen erzeugen, die im Anschluss dedupliziert werden sollten.

Bei Datenquellen, die nicht auf Forschungsdaten spezialisiert sind, sollte die Suche auf Publikationstypen eingeschränkt werden, die Gegenstand des Monitorings sind. Nach welchen Werten zu suchen ist, hängt davon ab, wie die Datenquelle Publikationstypen beschreibt. Wenn kein kontrolliertes Vokabular genutzt wird, ist auch hier empfehlenswert, nach mehreren Varianten und Schreibweisen zu suchen, beispielsweise nach “data”, “dataset” und “data set”. Bei der Wahl von Suchbegriffen kann z. B. das Vokabular COAR Resource Types zurate gezogen werden.²

Die größte Limitation dieses Ansatzes ist, dass er wesentlich von der Metadatenqualität der genutzten Datenquellen abhängt (Robinson-Garcia u. a. (2017)). Fehlende oder fehlerhafte Werte können das Ergebnis verfälschen.

3.2.2. Indirekte Suche

Da Affiliationsangaben in Metadaten, die Forschungsdaten beschreiben, häufig fehlen (Habermann (2025)), kann als weiterer Ansatz eine indirekte Suche über Verweise auf Datensätze in Textpublikationen wie Zeitschriftenartikel oder Data Paper herangezogen werden. Die Verknüpfung zwischen einem Datensatz und einer Einrichtung erfolgt bei diesem Ansatz mittelbar über eine Textpublikation, die sowohl einer Einrichtung zugeordnet werden kann als auch auf einen Datensatz verweist, der die vorgestellten Ergebnisse stützt. Einige Einrichtungen sammeln bereits den Publikationsoutput der Einrichtungsangehörigen, z. B. in einem FIS oder

¹Beispiel für Namensvarianten im ROR-Profil der Humboldt-Universität zu Berlin: <https://ror.org/01hcx6992>

²https://vocabularies.coar-repositories.org/resource_types/ (abgerufen am 30.09.2026)

in Form einer Hochschulbibliografie. Diese Sammlungen können als Basis dienen, zugehörige Datensätze zu finden. Auch der OA Monitor³ kann als Ausgangspunkt für diese Suchstrategie genutzt werden, da diese Datenquelle Textpublikationen mit wissenschaftlichen Einrichtungen verknüpft.

Der Verweis auf einen Datensatz kann sowohl im Literaturverzeichnis der Textpublikation als auch an anderer Stelle im Volltext, zum Beispiel im Methodenteil oder in einem Data Availability Statement, erfolgen. Gregory u. a. (2023) (S. 625) unterscheiden zwischen:

- data citation: Verweis auf Datensätze im Literaturverzeichnis
- data mention: Verweis auf Datensätze an anderer Stelle
- indirect data citation: Verweis auf eine Textpublikation statt des Datensatzes im Literaturverzeichnis

“Data citations” werden von verschiedenen Datenquellen erfasst, zum Beispiel vom Data Citation Corpus (DataCite und Make Data Count (2025)) oder von DataCite (DataCite (2026)). Allerdings gibt es große Abweichungen zwischen den Datenquellen in der Abdeckung von Zitationsbeziehungen (Gerasimov u. a. (2024) ; Strecker u. a. (2025)). Darum sollten unbedingt mehrere Datenquellen kombiniert werden, um Lücken auszugleichen.

Einige Einrichtungen extrahieren darüber hinaus bereits “data mentions”, also Verweise auf Datensätze in Textpublikationen, um den Forschungsdatenoutput zu bestimmen. Hier ist insbesondere ein Projekt am QUEST Center for Responsible Research am Berlin Institute of Health at Charité zu nennen, das einen eigenen Workflow und Algorithmus für diesen Ansatz entwickelt hat (Iarkaeva u. a. (2024) ; Riedel und Nachev (2026)). Die Methode ist jedoch für die Charité Universitätsmedizin Berlin und mit Fokus auf die Medizin entwickelt worden. Folglich kann diese Vorgehensweise nicht ohne Anpassung auf andere Institutionen oder Fachbereiche übertragen werden. Diese Anpassung hat das Team am Beispiel der Geowissenschaften für die Fachbibliothek Geowissenschaften an der Freien Universität Berlin⁴ demonstriert (Iarkaeva u. a. (o. J.)). Auch an der Universitätsbibliothek Mannheim wurden Workflows und Software entwickelt, um über die Extraktion von Verweisen auf Datensätzen aus Publikationen in der Universitätsbibliografie den Forschungsdatenoutput zu erfassen (Universitätsbibliothek Mannheim (2026)).

Im Rahmen der Prüfung der Treffermenge bei der Suchstrategie „indirekte Suche“ ist sicherzustellen, dass Fälle von “Datennachnutzung” ausgeschlossen werden sollten. Leider ist der Begriff „Datennachnutzung” nicht eindeutig definiert (Sandt u. a. (2019)). Näherungsweise können Datensätze, die nicht von den Autor:innen der Textpublikation selbst erstellt wurden (also “nachgenutzt” wurden), herausgefiltert werden. Das ist wichtig, da sie nicht zum Forschungsoutput der Einrichtung gehören und das Ergebnis verfälschen würden. Wie das Herausfiltern nachgenutzter Datensätze durch einen Abgleich der Autor:innen erfolgen kann, beschreiben Cohen u. a. (2026) für die Charité Universitätsmedizin Berlin.

³<https://open-access-monitor.de/> (abgerufen am 30.09.2026)

⁴<https://www.geo.fu-berlin.de/bibliotheken/geo/index.html> (abgerufen am 30.09.2026)

Dieser Ansatz bringt allerdings einige Limitationen mit sich. Zunächst hängt er wesentlich von den Zitationspraktiken der Forschenden ab. Studien zeigen, dass Forschende Datensätze oft nicht oder nur indirekt zitieren (Gregory u. a. (2023)). Auch hängt er von der Verfügbarkeit von Volltexten ab: Textpublikationen können nur nach Verweisen auf Datensätze durchsucht werden, wenn Zugriff auf die Volltexte besteht. Darum ist es möglich, dass dieser Ansatz für bestimmte Einrichtungen oder Fächerprofile nur unvollständige Ergebnisse liefert. Insgesamt ist die indirekte Suche ressourcenintensiver als die direkte Suche (Gee (2026)).

3.3. Datenquellen für die direkte Suche

Es gibt verschiedene Arten von Datenquellen, die für das Monitoring über die direkte Suche genutzt werden können. Datenquellen können beispielsweise unterschieden werden in individuelle Repositorien und Aggregatoren, die Metadaten aus mehreren Quellen zusammenführen. Einige Datenquellen sind spezialisiert auf Forschungsdaten, andere weisen darüber hinaus auch weitere Forschungsausgaben nach.

Grundsätzlich empfiehlt es sich, zunächst die für die eigene Einrichtung relevanten Datenquellen zu identifizieren. Dabei sollten Abdeckung, Metadatenschema, Zugänge und Ausgabeformate berücksichtigt werden. Um die Transparenz der Ergebnisse sicherzustellen, sollten nach Möglichkeit offene Datenquellen genutzt werden, wie die UNESCO Recommendations on Open Science nahelegen: “The monitoring of open science should be explicitly kept under public oversight, including the scientific community, and whenever possible supported by open non-proprietary and transparent infrastructures.” (*UNESCO Recommendation on Open Science* (2021) ; S. 34)

Es ist empfehlenswert, bei der Suche zunächst auf Aggregatoren zu setzen, da dies Ressourcen spart und einheitlichere Treffermengen liefert. Je nach Bedarf sollte darüber hinaus auch in individuellen Repositorien recherchiert werden – v.a. dann, wenn bekannt ist, dass Einrichtungsangehörige auch kleinere oder disziplinspezifische Repositorien nutzen, die bspw. keine DOIs vergeben (etwa Sequenzdatenbanken). Darüber hinaus kann eine Direktsuche in Repositorien zur Evaluation der Vollständigkeit der über Suchmaschinen gefundenen Publikationen herangezogen werden.

Da sich Datenquellen im Laufe der Zeit verändern können, etwa wenn das Metadatenschema aktualisiert wird, wird an dieser Stelle auf Beispiele für spezifische Abfragen verzichtet. Stattdessen werden wir voraussichtlich in Q1 2027 interaktive Notebooks veröffentlichen, die angepasst und ergänzt werden können.

Im Folgenden werden einige zentrale offene Datenbanken vorgestellt, die als Aggregatoren einen guten Einstieg in das Monitoring bieten können. Kriterien für die Auswahl von Datenquellen sind in der Infobox in [Kapitel 2](#) zu finden.

3.3.1. BASE

Typ	Suchmaschine ; Aggregator
Beschreibung	https://www.base-search.net/about/en/index.php
Abdeckung	Metadaten zu Forschungsoutputs, die von Datengebern über OAI-PMH-Schnittstellen zum Harvesting angeboten werden; Datenlieferanten
Metadaten-schema	oai-dc ; base-dc
Zugänge	GUI mit “ Erweiterter Suche ” ; API (OAI-PMH) ; Der Zugang via API ist ausschließlich für nicht-kommerzielle Zwecke gestattet und erfordert einen API-Key, der nach erfolgter Registrierung zur Verfügung gestellt wird (siehe https://ubib-baseapi.ub.uni-bielefeld.de/ , zuletzt aufgerufen am 02.09.2026). Das Anfragenlimit beträgt eine Anfrage pro Sekunde.
Suchfelder	Publikationstyp kann auf Forschungsdaten eingeschränkt werden (doctype:7) ;Kein Metadatenfeld für Affiliation / ROR ID vorhanden, daher muss mit Freitext gesucht werden.
Ausgabeformate	GUI: verschiedene Formate, u. a. JSON (kein csv) ; API: XML

3.3.2. DataCite

Typ	DOI registration agency ; Aggregator
Beschreibung	https://datacite.org/mission/
Abdeckung	Metadaten zu Forschungsoutputs, für die eine DOI bei DataCite vergeben wurde, sowie verwandte Publikationen (Quelle)
Metadaten-schema	DataCite Metadata Schema v4.7
Zugänge	DataCite Commons (GUI) ; DataCite REST API mit rate limits ; DataCite metadata dashboards (GUI) ; Die öffentliche REST API kann ohne Authentifizierung genutzt werden und wird von DataCite für das Abrufen und Suchen von DOI-Metadaten empfohlen.
Suchfelder	Im Tab “Organizations” kann mit ROR ID gesucht werden, dies führt zum Dashboard für die Institution. Die Treffermenge kann dann auf den work type „Dataset“ eingeschränkt werden.
Ausgabeformate	DataCite Commons: Download einer csv-Datei; DataCite REST API: JSON

3.3.3. OpenAIRE

Typ	Aggregator
Beschreibung	https://www.openaire.eu/faqs
Abdeckung	Zahlreiche europäische Datenquellen, darunter sowohl DOI-Agenturen und Aggregatoren als auch Repositorien (Quellenliste)
Metadaten-schema	JSON-Schema
Zugänge	OpenAIRE Explore (GUI) ; OpenAIRE Graph (API) ; Die öffentliche Graph API kann sowohl mit als auch ohne Authentifizierung genutzt werden. Das Anfragenlimit beträgt bei authentifiziertem Zugang 7200 Anfragen pro Stunde, bei unauthentifiziertem Zugang 60 Anfragen pro Stunde. Zur Authentifizierung ist ein API-Key erforderlich; dieser wird nach Erstellung eines Nutzeraccounts zur Verfügung gestellt.
Suchfelder	Institutionen sind als kontrolliertes Vokabular angelegt und können in der Advanced Search in Research products mit “Organization is” ausgewählt werden. Filter auf “Research Data” möglich
Ausgabeformate	GUI: csv

3.3.4. OpenAlex

Typ	Aggregator
Beschreibung	https://openalex.org/about
Abdeckung	Aggregatoren sowie Repositorien (Repositorien-Liste , Information zu Datenquellen , Noch eine Information zu Datenquellen)
Metadaten-schema	API Overview ___Institutionen werden automatisch zugeordnet (Beschreibung)
Zugänge	OpenAlex GUI , API , Snapshot ; Suchfilter Institution über die Nutzeroberfläche (mit Lookup) ; Ab Februar 2026 ist für die Nutzung der API im real-produktiven Maßstab ein API-Key erforderlich. Dieser wird nach der Erstellung eines Nutzeraccounts zur Verfügung gestellt und ist im Basismodell kostenlos. Das Anfragenlimit beträgt 100 Anfragen pro Sekunde und 100.000 Credits pro Tag.
Suchfelder	Im Suchfilter “Institution” können per Lookup Institutionen ausgewählt werden. Der Publikationstyp (“Type”) kann auf “dataset” gefiltert werden.

Typ	Aggregator
Ausgabeformate	GUI: vollständiger Export nach Login (kostenfrei), csv oder “csv excel-optimiert” (d. h. nicht zu viel Inhalt pro Zelle) ; REST API: JSON ; Snapshot: JSON, Parquet

4. Verwendung

Einrichtungen verfügen über unterschiedliche technische Möglichkeiten, die aus den verschiedenen Quellen erhobenen Daten zu verwenden. Je nach Zielsetzung (s. [Kapitel 2](#)) variieren die Zwecke und Prioritäten. Dieses Kapitel gibt zunächst einen Überblick über die möglichen Zielsysteme für die erhobenen Daten und skizziert anschließend den Ingest¹-Vorgang mit den zu berücksichtigenden Entscheidungen und Rahmenbedingungen.

4.1. Zielsysteme

4.1.1. Forschungsinformationssysteme

Die Verwendung eines FIS als Zielsystem liegt nahe, sofern die eigene Institution eines betreibt bzw. zur Verfügung stellt.

Es gibt verschiedene Softwarelösungen für ein FIS.² Im Folgenden wird eine Auswahl von FIS-Softwarelösungen inkl. einiger Besonderheiten ihres jeweiligen Umgangs mit Forschungsdaten vorgestellt.

- **DSpace-CRIS:** DSpace-CRIS unterstützt ein erweitertes, an Dublin Core und CERIF orientiertes Datenmodell, konfigurierbare Beziehungen, Workflows, ORCID-Anbindungen sowie REST-Schnittstellen.³ Ein eigener Dokumenttyp für Forschungsdatenpublikationen mit lokal individuell konfigurierten Metadatenfeldern ist beispielsweise möglich. Mit DSpace 10.0 wurde 2026 die Integration von DSpace-CRIS-Funktionen in den DSpace-Kern begonnen; der Funktionsumfang kann deshalb je nach verwendeter Softwareversion deutlich variieren.⁴
- **Pure:** Die Erfassung von Forschungsdaten ist als eigener Content-Type „Forschungsdaten“, „Datasets“ möglich. Verknüpfungen zu Personen, Organisationseinheiten etc. werden in Form von „Master data“ erfasst.⁵ In Pure lassen sich auch Berichte zum Forschungsdatenaufkommen einer Einrichtung umsetzen sowie eine (Zweit-)Veröffentlichung der gefundenen Forschungsdatensätze im Pure-eigenen Open Science Portal realisieren.

¹Mit „Ingest“ ist hier die Einspeisung in ein System gemeint. Da der englische Begriff im Deutschen geläufig ist, verwenden wir ihn im gesamten Dokument.

²https://kfid-online.de/fis_landkarte_visual/fis_landkarte_software.php (abgerufen am 30.09.2026)

³<https://4science.com/english-dspace-cris-7-has-landed/> (abgerufen am 30.09.2026)

⁴<https://dspace.org/dspace-10-0-released/> (abgerufen am 30.09.2026)

⁵<https://helpcenter.pure.elsevier.com/overview-of-content-types> (abgerufen am 30.09.2026)

- **Elements:** Die Erfassung von Forschungsdaten war in Elements seit jeher als eigener Datentyp (mit dem Anzeigenamen „Dataset“) möglich. Bei der Konfiguration von Elements kann der Datentyp zudem umbenannt werden (z. B. in „Forschungsdaten“) oder einen eigenen Datentyp mit einem eigenen Satz von Metadatenfeldern erstellen. Für Elements ist „Dataset“ ein Untertyp der Kategorie „Publikation“; die Kategorie lässt sich jedoch ebenfalls umbenennen (z. B. in „Scholar and Creative Work“, falls die semantische Bandbreite erhöht werden soll, bspw. mit Blick auf nicht veröffentlichte Forschungsdaten wie solche mit „restricted access“). Elements verfügt über eine Integration von Figshare, welche die Aufnahme von Metadaten zur Beschreibung von Forschungsdaten unterstützt und bei der Aufnahme einen Datensatz direkt mit einem Benutzer im Elements-Objektmodell verknüpft. Ebenso kann Elements so konfiguriert werden, dass es Metadaten zur Beschreibung von Forschungsdaten aus dem institutionellen Repositorium einer Einrichtung übernimmt. Derzeit unterstützt Elements Integrationen von DSpace, EPrints, Hyrax und Figshare for Institutions. Mittels der Elements-Benutzeroberfläche lassen sich Metadaten zur Beschreibung von Forschungsdaten hinzufügen; alternativ können sie über die Elements-API aus anderen strukturierten Datenquellen bezogen werden, sofern entsprechende Zugriffsrechte vorliegen.
- **Converis:** In der FIS-Software sind ebenfalls schon seit jeher individuelle Anpassungen am Datenmodell und Metadatenschema möglich; das System kann Publikationen, Personen, Organisationseinheiten, Projekte und weitere Forschungsinformationen zusammenführen und mit Repositorien sowie öffentlichen Forschungsportalen verbinden. Die Converis-Instanz der Universität Kassel enthält bspw. den Publikationstyp „Forschungsdatenpublikation“.⁶ Das FIS der Friedrich-Alexander-Universität Erlangen-Nürnberg basiert ebenfalls auf Converis und erfasst Forschungsdaten; die Entwickler:innen können zum Erfahrungsaustausch angesprochen werden.
- **HISinOne-RES:** Das System enthält Funktionalitäten für ein umfassendes Forschungsmanagement und orientiert sich beim Metadatenschema eng am Kerndatensatz Forschung (KDSF). Der KDSF-Systematik entsprechend gibt es einen Publikationstyp „Forschungsdaten“, der mit anderen Objekten wie Personen, Projekten und Förderinformationen verknüpft werden kann. Außerdem bietet die Software Optionen des automatisierten Ingests per API. Importmöglichkeiten bestehen via ORCID, RIS, BibTeX, OpenAlex und OAI-PMH. Um den Import von Metadaten aus Radar Local (RADAR XML) per API zu ermöglichen, hat die Universitätsbibliothek Würzburg ein XSLT-Stylesheet zur Metadaten transformation erstellt, welches seit Januar 2026 zusammen mit dem FIZ Karlsruhe auch zur Nachnutzung bereitgestellt wird.⁷

⁶https://forschung.uni-kassel.de/converis/portal/list?show=Publication&filter=%5Bfpubyear%3D%5D%2C%5Bpublicationtype%3D15998%5D&sortBy=pubYear&sortOrder=false&cypher=All&page=1&items=10&showAll=&treeView=false&moreOrLess=%5Bfpubyear%3Dtrue%5D%2C%5Bpublicationtype%3Dfalse%5D&auxfun=&lang=de_DE (abgerufen am 30.09.2026)

⁷<https://github.com/ER-FIZKarlsruhe/radar-stylesheets> (abgerufen am 30.09.2026)

4.1.2. Institutionelles Repository

Forschungsdaten bzw. ihre Metadaten können auch im institutionellen Repository, das entweder ein reines Forschungsdaten- oder ein gemischtes Daten- und Textrepository sein kann, verzeichnet werden. Institutionen entscheiden sich für das institutionelle Repository als Zielsystem beispielsweise, weil die Einrichtung kein Forschungsinformationssystem nutzt oder weil eine regelmäßige automatisierte Übertragung von Publikationsmetadaten vom Repository ins Forschungsinformationssystem bereits etabliert ist. Im zweiten Fall kann die bestehende Integration für die aus externen Quellen geharvesteten Metadaten ohne weitere Entwicklungsarbeit auf Forschungsdaten ausgeweitet werden.

Beispiele für Forschungsdatenrepositorien als Zielsysteme finden sich bei:

- [University of Virginia Dataverse](#)
- [Harvard Dataverse](#)
- [The Open University](#): „4.2 Where data have been archived in a repository other than ORDO or the OU Scholarship Exchange, a metadata-only record should be published on ORDO which describes the data and provides a persistent link (such as a DOI) to the data.”
- Baldwin und Green (2024)
- [University of Eastern Finland](#)

Die folgenden Softwarelösungen für Repositorien sind derzeit weit verbreitet:

- [MyCoRe](#)
- [DSpace](#) (das auch eine FIS-Version anbietet, siehe oben). In DSpace können diverse Publikationstypen mit jeweils eigenem Metadatensatz konfiguriert werden, ab Version 9 auch als eigenständige Entitäten, die miteinander in Beziehung gesetzt werden können.
- [EPrints](#) (EPrints (2015))
- [Invenio](#) (als Open-Source-Framework für groß anzulegende digitale Repositorien oder spezifisch InvenioRDM für Forschungsdaten)
- [RADAR](#) (In den Betriebsvarianten RADAR Local und RADAR Cloud)

Gegebenenfalls muss vor der Erfassung von Forschungsdaten zunächst ein Dokumenttyp oder eine Entität für Forschungsdaten angelegt werden.

4.1.3. Hochschulbibliografie und Bibliothekskatalog

Des Weiteren können Forschungsdaten in der Hochschulbibliografie verzeichnet oder in den Bibliothekskatalog aufgenommen werden.

Die Universität Heidelberg verzeichnet beispielsweise in ihrer Hochschulbibliografie heiBIB auch Forschungsdatenpublikationen.⁸ Ein weiteres Beispiel ist die Universität Bamberg, die seit Anfang 2022 Forschungsinformationen zu Forschungsdaten in ihrer Universitätsbibliografie im FIS verzeichnet und mit Forschungsinformationen zu Personen, Einrichtungen, Projekten, Publikationen und Auszeichnungen verknüpft (Ziegler und Franke (2023) ; S. 1 - 13).

Im gemeinsamen Katalog der Bibliotheksverbünde BVB und KOBV, B3Kat, können Forschungsdatenpublikationen manuell erfasst werden.⁹ Das Discovery-System EBSCO, das Daten an mehrere Bibliothekskataloge liefert, bezieht Metadaten unter anderem von der Bielefeld Academic Search Engine (BASE), die auch Forschungsdatenpublikationen verzeichnet. Auf diese Art gelangen Datenpublikations-Metadaten also auch automatisch über Umwege in manche Bibliothekskataloge.

Eine Art Hochschulbibliografie für Daten führt die University of Helsinki mit ihrem Data catalogue. „The metadata are gathered in Data catalogue through automatic data transfer (harvesting), and user submissions. For harvestable repositories, the researcher must have the ”University of Helsinki” in their affiliation for the metadata to appear in the Data catalogue.”¹⁰

4.2. Schritte zum Ingest in das Zielsystem

Nach den Vorarbeiten (s. [Kapitel 2](#)) und der Datensuche (s. [Kapitel 3](#)) sollen die identifizierten Publikationsmetadaten nun in das anvisierte Zielsystem überführt werden. Unabhängig vom konkreten Zielsystem umfasst der Ingest-Prozess die folgenden Schritte.

- **Abbildung, Sichtbarkeit und Berechtigungen festlegen** Um die erfassten Forschungsdaten importieren oder händisch eintragen zu können, muss sichergestellt sein, dass passende Metadatenfelder im Zielsystem existieren oder geschaffen werden können, idealerweise auf Basis bestehender gängiger Standards wie dem Kerndatensatz Forschung.¹¹ Das Zielsystem hat eine bestimmte Struktur mit festgelegten Elementen. Ein CRIS kann beispielsweise in Sammlungen für Fachbereiche organisiert sein und Entitäten wie „Artikel“, „Dissertation“, „Person“, „Projekt“ u. a. enthalten. Wie sollen die Metadaten der Datenpublikationen abgebildet werden? Gibt es bspw. einen Elementtyp „Dataset“ oder „Datensatz“? Die gewünschte Darstellungsform ist bei den weiteren Überlegungen (Ingest-Optionen, Metadatenschema) zu berücksichtigen. Ebenso sollte vorab geplant werden, welche Beschränkungen und Berechtigungen für die eingespielten Daten gelten sollen (read / write). Je nachdem, wie diese im Zielsystem organisiert sind, können oder

⁸<https://heibib.ub.uni-heidelberg.de/search/Search/Results?type=AllFields&filter%5B%5D=format%3A%22Research+Data%22> (abgerufen am 30.09.2026)

⁹<https://www.bib-bvb.de/web/kkb-online/forschungsdaten> (abgerufen am 30.09.2026)

¹⁰<https://www.helsinki.fi/en/research/services-researchers/data-support/preservation-research-data/data-catalogue> (abgerufen am 30.09.2026)

¹¹<https://www.kerndatensatz-forschung.de/kdsf20/kdsf20.php> (abgerufen am 30.09.2026)

sollten die Berechtigungen direkt beim Ingest gesetzt werden, bspw. über entsprechende Metadatenfelder oder zusätzliche Angaben im Ingest-Prozess.

- **Ingest-Optionen des Zielsystems prüfen** In den meisten Fällen ist eine manuelle Eingabe der Publikationsmetadaten nicht wünschenswert. In manche Systeme (z. B. DSpace) können Daten in strukturierter Form (z. B. als CSV-Datei mit bestimmten Spaltenbezeichnungen, oder im OAIS-Format) importiert werden. Möglicherweise steht auch eine API für den Import zur Verfügung. Für den Import müssen ggf. die nötigen Berechtigungen erteilt werden.
- **Metadatenchema des Zielsystems prüfen** Das Metadatenchema des Zielsystems kann von denen der genutzten Datenquellen abweichen. Beispielsweise können die Namen der Autor:innen im Metadatenfeld dc.contributor.author stehen, in dcterms.creator oder in Feldern aus noch anderen Metadaten schemata. Damit die Metadaten korrekt in das Zielsystem übertragen werden, muss ein Mapping zwischen dem Metadaten schema der Treffermenge auf das des Zielsystems erstellt werden.
- **Datensatz-Metadaten auf Zielsystem anpassen** Anschließend werden die Publikationsmetadaten transformiert, um a) dem Metadaten schema des Zielsystems und b) ggf. der für den Ingest erforderlichen strukturierten Form zu entsprechen. Für diesen Schritt ist eine gute Dokumentation von besonderer Bedeutung, um eine wiederholte oder regelmäßige Durchführung vorzubereiten. Die Dokumente für die Transformation können ggf. auch veröffentlicht werden, um die Nachnutzung durch Dritte zu ermöglichen.
- **Ingest testen** Vor dem Komplet-Ingest ist ein Test mit begrenztem Umfang (z. B. 10 Publikationen) unbedingt empfehlenswert.
- **Ingest durchführen** War der Test erfolgreich, kann der Ingest vollständig durchgeführt und anschließend geprüft werden.
- **Überprüfen und dokumentieren** Eine Überprüfung des Ingests, entweder stichprobenartig oder automatisiert und vollständig, ist angeraten. Eine gute Dokumentation hilft, wie immer, sowohl bei der Identifizierung von Fehlerquellen als auch bei einer potentiellen erneuten Ausführung zu einem späteren Zeitpunkt.

5. Vorbereitung

Bestimmte Rahmenbedingungen können die Erfassung des Forschungsdatenoutputs an einer Einrichtung erleichtern. Das ist insbesondere bei permanentem Monitoring relevant, also wenn die Erfassung in regelmäßigen Abständen wiederholt werden soll. Im Folgenden wird auf einige dieser Rahmenbedingungen eingegangen und beschreiben Maßnahmen beschrieben, die zukünftige Monitoringaktivitäten unterstützen können. Die beschriebenen Maßnahmen betreffen neben dem Sammeln der Metadaten auch die Motivation und Befähigung von Forschenden.

5.1. Organisatorische Maßnahmen für Sammlungen

Mit gezielten Maßnahmen können Prozesse und Infrastrukturen besser auf die Erfassung von Forschungsdatenpublikationen vorbereitet werden. Da Voraussetzungen an jeder Einrichtung sehr vielseitig sein können, dienen die genannten Beispiele primär der Orientierung.

5.1.1. Leit- und Richtlinien

Um einen Rahmen für das Monitoring von Forschungsdatenpublikationen zu schaffen und entsprechende Abfragen zu vereinfachen, können Einrichtungen die Absicht einer möglichst vollständigen Erfassung in Open-Science- oder Forschungsdatenleitlinien aufnehmen. Eine verpflichtende Erfassung sieht beispielsweise die Research Data Management Policy der Buckinghamshire New University vor: „All research data must be registered with the University whether it is hosted by the University or retained elsewhere” (Buckinghamshire New University (2016) ; S. 3). Hierbei lassen sich auch Regelungen zur Nutzung des institutionellen Repositoriums und zu Communities der Institution in externen Repositorien wie Zenodo festhalten.

Formulierte Vorgaben und Handreichungen zielen darauf ab, eine bestmöglichen Angabe von Metadaten bei Forschungsdatenpublikationen durch die Autor:innen der eigenen Einrichtung zu erreichen. Dies umfasst neben der korrekten Affiliationsangabe, etwa festgelegt durch eine Affiliationsrichtlinie, auch die Förderung der Nutzung von persistenten Identifikatoren für Einrichtungen (ROR) und Autor:innen (ORCID). Affiliationsrichtlinien werden in der Regel nach Abstimmung mit dem Präsidium erarbeitet und vom Senat verabschiedet. Viele universitäre Einrichtungen haben eine Affiliationsrichtlinie, beispielsweise die TU Clausthal.¹

¹<https://doi.org/10.21268/20260119-0>

5.1.2. Institutsseitige Empfehlungen für die Repositorienwahl

Es gibt eine Vielzahl von Forschungsdatenrepositorien, die sich mit Blick auf ihren Anwendungsbereich, die technische Basis, Implementierung von Standards und weiteren Eigenschaften unterscheiden. Das Verzeichnis re3data weist inzwischen mehr als 3500 Repositorien nach.² Forschungsförderer und Akteure wie z. B. DINI definieren vermehrt Anforderungen an geeignete Forschungsdatenrepositorien, um Forschende Orientierung bei der Repositorienwahl zu geben (Gollwitzer u. a. (2020)). Auch Einrichtungen können Empfehlungen aussprechen, wie etwa die ETH Zürich in den „Guidelines for Research Data Management at ETH Zurich“³ oder die Forschungsdatenleitlinie der Max-Weber-Stiftung⁴.

Durch Empfehlungen wie diese können Einrichtungen ihre Angehörigen an Forschungsdatenrepositorien verweisen, die gewünschte Eigenschaften aufweisen. Hierzu zählen beispielsweise die Nutzung persistenter Identifikatoren oder das Harvesten der Datensätze durch Aggregatoren. Wenn Forschende ihre Daten dort veröffentlichen, wird die zukünftige Erfassung des Publikationsoutputs erleichtert.

5.1.3. Technische Voraussetzungen schaffen

Je nach gewünschtem Verfahren (s. Kapitel 3) und Voraussetzungen des Zielsystems (s. Kapitel 4) können (semi-)automatisierte Importroutinen implementiert werden. Das für die Erfassung zuständige Team kann unabhängig von Forschenden Einträge importieren. Auch manuelle Such- und Erfassungsvorgänge sind – mit entsprechendem Aufwand – denkbar, etwa für einen anlassbezogenen Überblick (s. Kapitel 2.1).

5.1.4. Teilnahme am ORCID-DE Konsortium

Sofern es keine vertragliche Verpflichtung gibt, obliegt die Entscheidung, einen persönlichen ORCID-Account einzurichten und zu pflegen, jedem Forschenden selbst. Während das Einrichten und die Angabe der ORCID meist ohne Unterstützungs- oder Korrekturbedarf abläuft, erfolgt die aktive Pflege der Einträge nicht immer konsequent. Einrichtungen, die Mitglied im ORCID-DE Konsortium sind, erhalten die Möglichkeit, die ORCID-Einträge ihrer Forschenden zu kuratieren und sie somit bei der Pflege des Accounts zu unterstützen. Der Zugriff auf die ORCID-Einträge erfolgt von technischer Seite über eine API und bedarf der expliziten Zustimmung des jeweiligen Forschenden. Weitere Informationen zum Vorgang sind unter <https://www.orcid-de.org/konsortium/ueber-das-konsortium> und auf den verknüpften Seiten zu finden.

²<https://www.re3data.org> (abgerufen am 30.09.2026)

³<https://ethz.ch/content/dam/ethz/main/eth-zurich/organisation/rechtssammlung/414.2en.pdf> (abgerufen am 30.09.2026)

⁴<https://doi.org/10.5281/zenodo.10219502>

Durch diese Serviceleistung kann die Akzeptanz der ORCID bei Forschenden erhöht und zugleich die Metadatenqualität in den institutseigenen Forschungsinformationssystemen verbessert werden. Dennoch ist an dieser Stelle anzumerken, dass die Konsortialmitgliedschaft nicht kostenlos ist. Einrichtungen müssen hier abwägen, ob sie den Mitgliedsbetrag aufbringen können bzw. wollen. Auch der erforderliche Personaleinsatz für die Datenpflege sollte bedacht werden.

5.2. Motivation und Befähigung von Forschenden

Die Einbindung von Forschenden in den Prozess der Sammlung und Sichtbarmachung des Forschungsoutputs der eigenen Einrichtung bereits während des Publikationsprozesses kann zu einer Verbesserung der Metadatenqualität führen und so das spätere Auffinden der Datensätze sowie das Transferieren in andere Systeme erleichtern. Wesentliche Punkte bei diesem Vorgehen sind die Motivation und die Befähigung der Forschenden, sich aktiv in den Prozess einzubringen. Hierfür müssen seitens der Einrichtung die Rahmenbedingungen in Form von Leit- und Richtlinien ausgearbeitet, verabschiedet und veröffentlicht werden. Außerdem können Anreize geschaffen werden, die das Mitwirken der Forschenden positiv beeinflussen. Um die Forschenden über ihre Rolle im Prozess, das damit verbundene Ziel und die zugrundeliegenden Bedingungen aufzuklären sowie dafür zu sensibilisieren, ist eine zielgerichtete Informationsbereitstellung von großer Bedeutung.

5.2.1. Anreizsysteme

Die Publikation von Forschungsdaten sowie die damit verknüpfte Beachtung der Leit- und Richtlinien lassen sich durch bestimmte Anreizmechanismen fördern.

Durch die Berücksichtigung von Open-Science-Praktiken in Einstellungs- und Evaluationsverfahren oder in der leistungsorientierten Mittelvergabe können Anreize für die Veröffentlichung von Forschungsdaten gesetzt werden. Dies erfolgt bereits an einigen Einrichtungen, wie eine internationale Sammlung von Stellenausschreibungen zeigt (Schönbrodt u. a. (2018)). Darüber hinaus können Datenpublikationen inkl. korrekter Affiliationsangaben durch Preise honoriert werden.

5.2.2. Informationsangebote für Forschende

Um die Forschenden als aktive Akteure über die anvisierte Sammlung und die damit designierte Verbesserung der Sichtbarkeit von Forschungsdaten der eigenen Einrichtung zu sensibilisieren, sind zielgerichtete Informationen – auch über die am jeweiligen Standort herrschende Verbindlichkeit der Umsetzung - essentiell.

Die Informationsangebote können die folgenden Aspekte in Bezug auf die Datenpublikation behandeln (soweit zutreffend):

- die Nutzung persistenter Identifier (insbesondere DOI, ORCID, ROR)
- die Wahl eines Repositoriums (Auswahlkriterien, empfohlene Repositorien, Verweis auf das institutionelle Repository)
- Institutsseitige Vorgaben
 1. Forschungsdatenleitlinie oder Open-Science-Leitlinie
 2. Affiliationsrichtlinie
 3. Leitlinien für die Datenaufnahme und -kuration in Repositorien (z. B. in Zenodo-Communities)
 4. Vorgaben zur Dateneinspeisung ins FIS
 5. Honorierung guter Praxis bei Einstellungsverfahren
- FAIR Data Principles

Forschende können hierbei über unterschiedliche Kommunikationskanäle erreicht werden. Dafür bieten sich die folgenden Wege an:

- Internetseiten des lokalen Forschungsdatenmanagements oder der zugehörigen Universitätsbibliothek
- Unterlagen in Onboarding- und Offboarding-Verfahren
- Newsletter
- Leitlinien und Handlungsempfehlungen

Eine dynamische Informationsbereitstellung kann unter anderem durch die direkte Interaktion mit den Forschenden auf Informationsveranstaltungen, Multiplikatorveranstaltungen (z. B. Sitzungstermine im Senat oder Fakultätsrat), in Onboarding-Gesprächen und in gezielten Schulungen erfolgen.

Hierbei ist hervorzuheben, dass erfahrungsgemäß insbesondere (Post-)Doktoranden gut über Schulungen und Workshops zu Themen des Forschungsdatenmanagements erreichbar sind, aber auch andere Zielgruppen können durch spezialisierte Angebote angesprochen werden.

Neben dem FDM- und Bibliothekspersonal werden hinsichtlich der Kommunikation mit den Forschenden aber auch die Präsidiumsmitglieder, welche für das Ressort Forschung zuständig sind, in der Verantwortung gesehen, sich unterstützend einzubringen. Eine vom Präsidiumsmitglied verfasste Rundmail, in der die Forschenden dazu ermutigend aufgefordert werden, eine ORCID anzulegen und zu pflegen, die Affiliationsrichtlinie zu beachten oder bestimmte Vorgaben bei der Datenpublikation zu erfüllen, kann eine verstärkende Wirkung besitzen.

6. Zusammenfassung

Abschließend lässt sich festhalten, dass ein institutionelles Monitoring dezentral publizierter Forschungsdaten realisierbar, aber mit einigen Herausforderungen verbunden ist.

Zu den Herausforderungen gehört insbesondere der Ressourceneinsatz, der für die Umsetzung erforderlich ist, und die Limitationen der verwendeten Datenquellen, z. B. mit Blick auf deren Datenqualität oder Veränderlichkeit (Demes (2026)). Auch das Policy-Umfeld ist geprägt von dynamischen Entwicklungen. So diskutieren verschiedene Akteure die Berücksichtigung von Open-Science-Praktiken in Evaluations- und Berufungsverfahren und setzen damit Anreize für die Erfassung des Forschungsdatenoutputs, und die internationale Open Science Monitoring Initiative fördert den Austausch und setzt sich für mehr Standardisierung ein. Diese Entwicklungen können schwer zu überblicken sein.

Das Monitoring des institutionellen Forschungsdatenoutputs ist ein umfangreiches Vorhaben, das nicht nur ein Verständnis für institutionelle Gegebenheiten, Datenquellen und Suchstrategien, sondern auch zumindest grundlegende technische Fähigkeiten voraussetzt. Das Monitoring betrifft darüber hinaus verschiedene Bereiche der Einrichtungen und profitiert darum von klaren Zuständigkeiten und Vorgaben.

Diese Handreichung zeigt auf, dass erste Schritte möglich sind, die schrittweise ausgebaut und so immer bessere Ergebnisse liefern können. Das Dokument sammelt Erfahrungen und bereitet sie in einer Form auf, die hoffentlich anderen Interessierten den Einstieg in das Thema erleichtert. Dieses Dokument wird zukünftig ergänzt um Notebooks, die konkrete Beispiele für Suchanfragen liefern.

Literaturverzeichnis

- Baldwin, Julie, und Jonathan Green. 2024. *Instant Data Finding and cataloguing externally hosted research datasets through automation*. Figshare. <https://doi.org/10.6084/M9.FIGSHARE.25233181>.
- Bobrov, Evgeny, Laetitia Bracco, Marin Dacos, u. a. 2025. *The Principles of Open Science Monitoring*. <https://doi.org/10.5281/zenodo.17853227>.
- Buckinghamshire New University. 2016. *Research Data Management Policy*. https://www.bucks.ac.uk/sites/default/files/2021-03/research_data_management_policy.pdf.
- Cohen, Avihay, Blanka Ivanovic, Anastasiia Iarkaeva, Vladislav Nachev, und Evgeny Bobrov. 2026. *Matching data references and institutional output to map the reuse of biomedical research data*. z9kjf_v4. MetaArXiv. https://doi.org/10.31222/osf.io/z9kjf_v4.
- DataCite. 2026. *DataCite Public Data File 2025*. DataCite. <https://doi.org/10.14454/T5QB-D995>.
- DataCite, und Make Data Count. 2025. *Data Citation Corpus Data File*. Version v3.0. Zenodo. <https://doi.org/10.5281/zenodo.14897662>.
- Demes, Kyle. 2026. „An Overhaul of Type Classification. OpenAlex blog“. Juli 15. <https://blog.openalex.org/an-overhaul-of-type-classification/>.
- EPrints. 2015. „EPrints for Research Data– EPrints Services“. Juli 9. <https://uk.eprints-hosting.org/uk/index.php/flavours/eprints-for-research-data-1/>.
- Gee, Bryan M. 2026. „The hunt for research data: Development of an open-source workflow for tracking institutionally-affiliated research data publications“. *Journal of eScience Librarianship* 15 (1). <https://doi.org/10.7191/jeslib.1170>.
- Gerasimov, Irina, Binita KC, Armin Mehrabian, James Acker, und Michael P. McGuire. 2024. „Comparison of datasets citation coverage in Google Scholar, Web of Science, Scopus, Crossref, and DataCite“. *Scientometrics* 129 (7): 3681–704. <https://doi.org/10.1007/s11192-024-05073-5>.

- Gollwitzer, Mario, Andrea Abele-Brehm, Christian Fiebach, u. a. 2020. *Management und Bereitstellung von Forschungsdaten in der Psychologie: Überarbeitung der DGPs-Empfehlungen*. PsyArXiv. <https://doi.org/10.31234/osf.io/hcxtm>.
- Gregory, Kathleen, Anton Ninkov, Chantal Ripp, Emma Roblin, Isabella Peters, und Stefanie Haustein. 2023. „Tracing data: A survey investigating disciplinary differences in data citation“. *Quantitative Science Studies* 4 (3): 622–49. https://doi.org/10.1162/qss_a_00264.
- Habermann, Ted. 2025. „DataCite Facets and Metadata Completeness. Metadata Game Changers“. <https://doi.org/10.59350/55etd-e8154>.
- Iarkaeva, Anastasiia, Maaike Duine, und Andreas Hübner. o. J. *Methodology to detect Open Data underlying the journal articles' full texts of the Department of Earth Sciences, Freie Universität Berlin*. <https://doi.org/10.57874/Z5FK-WE46>.
- Iarkaeva, Anastasiia, Vladislav Nachev, und Evgeny Bobrov. 2024. „Workflow for detecting biomedical articles with underlying open and restricted-access datasets“. *PLOS ONE* 19 (5): e0302787. <https://doi.org/10.1371/journal.pone.0302787>.
- Kirsch, Danielle R., und Isaac Wink. 2026. „Assessing Researcher Data Sharing Practices Using Publicly Available Dataset Metadata: A Reproducible Workflow for Institutional Stakeholders“. *Journal of Librarianship and Scholarly Communication* 14 (1). <https://doi.org/10.31274/jlsc.22913>.
- Putnings, Markus, Anna Daudrich, Nils Dille, Anastasiia Iarkaeva, Janina Kühner, und Alica Wollmann. 2024. *GO UNITE! Empfehlungen zur Sammlung und Sichtbarkeit von Forschungsdaten der eigenen Institution*. Zenodo. <https://doi.org/10.5281/zenodo.11102368>.
- Riedel, Nico, und Vladislav Nachev. 2026. *ODDPub: A text-mining algorithm to detect data sharing in biomedical publications*. Version 7.3.0. Released. <https://doi.org/10.5281/zenodo.3741403>.
- Robinson-Garcia, Nicolas, Philippe Mongeon, Wei Jeng, und Rodrigo Costas. 2017. „DataCite as a novel bibliometric source: Coverage, strengths and limitations“. *Journal of Informetrics* 11 (3): 841–54. <https://doi.org/10.1016/j.joi.2017.07.003>.
- Sandt, Stephanie van de, Sünje Dallmeier-Tiessen, Artemis Lavasa, und Vivien Petras. 2019. „The Definition of Reuse“. *Data Science Journal* 18 (1): 22. <https://doi.org/10.5334/dsj-2019-022>.
- Schönbrodt, Felix, Leonhard Schramm, Franka Etzel, u. a. 2018. *Academic job offers that mentioned open science*. OSF. <https://doi.org/10.17605/OSF.IO/7JBNT>.

- Strecker, Dorothea, Kerstin Soltau, und Felix Bach. 2025. „How Are Research Data Referenced? The Use Case of the Research Data Repository RADAR“. *Research Data Management: Challenges in a Changing World* (Heidelberg), 146–59. <https://doi.org/10.11588/heibooks.1652>.
- UNESCO Recommendation on Open Science*. 2021. UNESCO. <https://doi.org/10.54677/MNMH8546>.
- Universitätsbibliothek Mannheim. 2026. *UB-Mannheim/madabi*. Released. <https://github.com/UB-Mannheim/madabi>.
- Ziegler, Barbara, und Fabian Franke. 2023. „6 in 1: Publikationen, Forschungsdaten, Projekte, Forschende, Einrichtungen, Auszeichnungen“. *o-bib. Das offene Bibliotheksjournal* 10 (1): 1–13. <https://doi.org/10.5282/O-BIB/5868>.

Teil II.

Notebooks